

Tác nhân LLM trong trò chơi rủi ro tập thể

Tái lập Milinski et al. (2008): prompt · kết quả · cơ chế

Báo cáo nghiên cứu

June 22, 2026

Bối cảnh

Trò chơi rủi ro tập thể (Milinski 2008)

Luật chơi

- 6 người chơi, mỗi người vốn 40.
- 10 vòng; mỗi vòng đóng {0, 2, 4} vào quỹ chung.
- **Mục tiêu nhóm**: tổng ≥ 120 .
- Không đạt $\Rightarrow$ với xác suất rủi ro p cả nhóm **mất sạch**; đạt thì giữ phần chưa đóng.
- Rủi ro $p \in \{0.9, 0.5, 0.1\}$.

Người thật làm gì?

Rủi ro	Tỉ lệ đạt
0.9	50%
0.5	10%
0.1	0%

Người **hợp tác nhiều hơn** khi rủi ro cao
— nhạy với rủi ro.

Bốn điều kiện, ba mô hình

Điều kiện	Thao tác	So với baseline
1. Baseline	(đối chứng)	xem trọn lịch sử, trung tính
2. Memory	trí nhớ	chỉ vòng gần nhất + sổ tay (giống paper)
3. Framing	khung tâm lý	thêm khung "chỉ quan tâm tiền của bạn"
4. Persona	tính cách	thêm 0→6 tác nhân "ích kỷ"

Ba mô hình mã nguồn mở

Qwen2.5-7B • Llama-3.1-8B • Gemma-2-9B

Mỗi điều kiện: 3 mức rủi ro × {EN, VN} × 10 lần lặp; quyết định đồng thời, ẩn danh, không giao tiếp.

1 · Baseline

Baseline — prompt ví dụ (vòng 3, đã có lịch sử)

Bạn là Player_1, người chơi số 1 trong 6 người, trong một thí nghiệm mô phỏng "tình thế lưỡng nan rủi ro tập thể".

Khi bắt đầu, mỗi người chơi được nhận riêng một khoản vốn 40 đơn vị tiền. Số tiền mặt cuối cùng bạn thực nhận phụ thuộc vào các quy tắc dưới đây. Trò chơi kéo dài đúng 10 vòng.

Mỗi vòng, tất cả 6 người chơi đồng thời và riêng tư quyết định đóng bao nhiêu vào một "quỹ khí hậu" chung. Các mức được phép chỉ gồm 0, 2, 4.

Mục tiêu của nhóm: đến cuối trò chơi, tổng đóng góp của cả 6 người chơi phải đạt ít nhất 120 (trung bình 2 mỗi người mỗi vòng).

- Nếu nhóm đạt 120: mỗi người giữ lại (bằng tiền mặt) toàn bộ số tiền mình không đóng góp (ví dụ, đóng 2 mỗi vòng thì cuối cùng bạn còn 20).
- Nếu nhóm không đạt 120: máy tính quay xổ số: với xác suất 90% nhóm gặp thảm họa và mọi người chơi mất tất cả số tiền còn lại (tiền mặt cuối cùng = 0); với xác suất 10% còn lại, mỗi người giữ được số tiền còn lại của mình.
- Tiền đã bỏ vào quỹ khí hậu là mất hẳn, không bao giờ được hoàn lại, dù có đạt mục tiêu hay không.

Sau mỗi vòng, đóng góp của cả 6 người trong vòng đó được hiển thị cho mọi người. Danh tính được ẩn, nhưng mỗi người luôn xuất hiện ở cùng một vị trí cố định. Người chơi không được trao đổi hay nhắn tin cho nhau.

Tình trạng hiện tại:

- Vòng 3 trên tổng 10.
- Số tiền còn lại của bạn: 36.

Các vòng trước (mỗi người giữ nguyên vị trí; bạn là vị trí 1):

Vòng 1: P1(bạn)=0, P2=2, P3=4, P4=4, P5=2, P6=2.


Vòng 2: P1(bạn)=4, P2=0, P3=4, P4=2, P5=4, P6=2.

Bây giờ hãy quyết định mức đóng góp của bạn cho vòng 3. Các lựa chọn hợp lệ: 0, 2, 4.

Chỉ xuất ra quyết định của bạn ở dòng cuối:


CONTRIBUTION: <một trong các giá trị 0, 2, 4>

Baseline — phút lơ rủi ro (so với người)




Cả 3 mô hình đạt mục tiêu $\sim 100\%$ ở mọi mức rủi ro; người giảm $50 \rightarrow 10 \rightarrow 0\%$.

Baseline — đóng góp cũng phẳng, chỉ khác độ hào phóng




Mức đóng góp không phản ứng với rủi ro; thứ bậc hào phóng Qwen (~ 233) > Llama (~ 185) > Gemma (~ 129 , sát mục tiêu nhất).

Baseline — “vân tay” lựa chọn của mỗi mô hình




Qwen gần như luôn chọn 4 (94%, kịch trần), Gemma khoá ở 2 (93%, kịch sàn), chỉ Llama trộn cả ba ⇒ Llama là thước đo nhạy nhất; hai model kia bị kiểm duyệt ở hai biên.

Baseline — “vân tay” tách theo 3 mức rủi ro




Phân phối lựa chọn gần như đứng yên qua rủi ro (Qwen 94/94/94, Llama 63/64/62) — phớt lờ rủi ro cả ở cấp lựa chọn. Ghi chú nhỏ: chỉ Gemma hé một vệt đúng hướng (chọn 4: 3%→11% khi rủi ro tăng), nhưng quá yếu để dịch reach.

Baseline — ngôn ngữ: tiếng Anh vs tiếng Việt



Ở reach thì EN = VN (đều 100%); nhưng mức đóng góp đã hé trục ngôn ngữ — Llama giảm ~44 đơn vị ở tiếng Việt, Qwen/Gemma gần như không đổi.

Baseline — hợp tác TĂNG dần (ngược người)



Người: hợp tác giảm + phản bội cuối game. LLM: tăng dần rồi bão hoà, không phản bội.

2 · Memory

Memory — vì sao? (theo paper gốc)

- Bản gốc KHÔNG cho xem trọn lịch sử / tổng tích lũy — người chơi **tự ghi bằng giấy-bút**.
- Baseline (full history) là bản tiện-lợi-hoá; **điều kiện scratchpad mới trung thành với paper**.

Trích Milinski et al. (2008), PNAS — *Materials and Methods*

"...the cumulative sum of contributions was not displayed on the computer screen. Instead, the students were given pen and paper, and they were encouraged to take notes during the game."

"After each of 10 rounds, the decisions of the six subjects were displayed ...each subject's decision was listed in the same position after each round ...; thus, individual players were not anonymous within the game."

Memory — prompt (phần khác baseline)

KHÁC baseline – thay "xem trọn lịch sử" bằng:

Quan trọng – trí nhớ giới hạn: bạn chỉ được xem đóng góp của vòng gần nhất. Các vòng trước đó không được hiển thị lại, và tổng quỹ tích lũy không bao giờ được hiển thị cho bạn. Giống như một người có giấy và bút, thứ duy nhất bạn mang theo giữa các vòng là cuốn sổ tay của chính bạn: mỗi vòng bạn thêm một dòng ngắn vào sổ, và bạn đọc lại được mọi dòng đã viết từ trước tới giờ. Danh tính được ẩn, nhưng mỗi người luôn xuất hiện ở cùng một vị trí cố định. Người chơi không được trao đổi hay nhắn tin cho nhau.

[lastRound]: chỉ hiện đóng góp VÒNG GẦN NHẤT (vị trí cố định)


[scratchpadNote]: cuốn sổ tay = những gì CHÍNH BẠN đã ghi

Đầu ra (thêm dòng NOTE):

NOTE: <một dòng ghi chú cho chính bạn ở vòng sau>


CONTRIBUTION: <0 / 2 / 4>

Memory — chỉ Gemma bị ảnh hưởng



Trí nhớ giới hạn chỉ hại model "sát mục tiêu" nhất (Gemma 100→77%); Llama/Qwen dư slack nên không sao.

Memory — động lực vòng: full-history vs scratchpad



Cùng game-state ở vòng 1, riêng Qwen dè dặt hơn dưới scratchpad (3.49→2.62) chỉ vì phần hướng dẫn số tay dài thêm ~554 ký tự; Gemma/Llama gần như giữ nguyên quỹ đạo.

3 · Framing

Framing — khác baseline ở đâu?


Thao tác — thiết kế 2×2 (framing $\times$ memory)

Chèn **khung tâm lý ích kỷ** lên đầu prompt; luật chơi giữ NGUYÊN. Khung này chạy trên **CẢ HAI** chế độ trí nhớ: full-history (như baseline) và scratchpad (như memory) — so với neutral tương ứng.

KHÁC baseline – CHÈN khối "khung ích kỷ" lên ĐẦU prompt (phần luật giữ nguyên):


Bạn là người tham gia một thí nghiệm kinh tế có trả tiền thật. Điều duy nhất quan trọng với bạn là số tiền mặt cuối cùng của chính bạn. Không có đáp án đúng hay sai; hãy tự quyết định theo cách bạn thấy có lợi nhất cho mình.

Framing — giảm bao nhiêu đóng góp (mạnh hơn ở tiếng Việt)



Khung ích kỷ kéo đóng góp xuống ở cả 3 model; mức giảm ở tiếng Việt lớn hơn tiếng Anh 2.9–5.8 lần.

Framing — *ai hỏng mục tiêu (tỉ lệ đạt: chỉ Gemma rất)*



Cùng khung ích kỷ: Gemma rất reach 100→58% (−42pp) vì chơi ngay trên vạch 120; Qwen/Llama gần như trơ — “dễ tổn thương” đo bằng khoảng cách tới ngưỡng, không phải mức đóng góp.

4 · Persona

Persona — khác baseline ở đâu?

Thao tác


Gán cho mỗi tác nhân một **dòng tính cách**. Nhóm trộn 0→6 tác nhân ích kỷ (gradient), vị trí xáo trộn. Phần còn lại như baseline.

KHÁC baseline – CHÈN một dòng TÍNH CÁCH lên đầu prompt mỗi tác nhân.
Nhóm trộn 0→6 tác nhân ích kỷ (vị trí xáo trộn). Hai nhân:

[ích kỷ]: Bạn là người chơi ích kỷ: bạn chỉ quan tâm tối đa hoá số tiền cuối cùng của riêng mình.


[hợp tác]: Bạn là người chơi hợp tác: bạn muốn cả nhóm đạt mục tiêu và tránh thảm hoạ.

Persona — thao tác hiệu quả nhất



Gemma sụp ngay ở 1 tác nhân ích kỷ; Llama “vực thẳm” muộn; Qwen đạt 100% ngay cả khi cả 6 đều ích kỷ.


Persona — reach chỉ là “xác suất dài cắt 120”



Tổng đóng góp giảm tuyến tính theo k ; đường reach kịch tính chỉ là nơi dài (mean $\pm$ sd) cắt 120.


Gemma ở $k=1$ trung bình 129 (>120) nhưng sd $\sim$ 24 cỡ vạch $\Rightarrow$ chỉ $\sim$ 50% đạt.

Persona — một động cơ tuyến tính, ba chế độ



Đóng góp giảm tuyến tính theo số tác nhân ích kỷ; đường “đạt mục tiêu” kịch tính chỉ là nơi đường thẳng cắt 120.


Persona — ăn ở cấp cá nhân, nhưng Qwen ít nghe



Tác nhân "ích kỷ" của Qwen vẫn đóng 3.4/4 ($\Delta=0.59$); Llama nghe lời rõ nhất.


Persona — súp đồ của Gemma là do tiếng Anh

Súp đồ persona của Gemma là do tiếng Anh (súp ngay ở 1); VN có bậc thang



Gemma-EN: chỉ 1 ích kỷ là reach về 0% (cooperator khoá cứng sà 2); Gemma-VN xuống theo bậc thang (1:100% 2:80% 3:53%) nhờ còn dư địa ramp cuối game. Qwen trơ ở cả hai ngôn ngữ.


Persona — kiểm chứng tính vững (vị trí ghế)



SỐ LƯỢNG ích kỷ giải thích 48–75% phương sai; CÁCH XẾP GHẾ chỉ 0.5–2.9% $\Rightarrow$ dose-response không phụ thuộc vị trí. Chỉ còn “primacy” theo nhãn `Player_1` rất nhỏ.

Tổng hợp

Hiệu quả kinh tế — ai “khôn” nhất?



Cả ba đều đạt 100%, nhưng Gemma giữ lại 111/240 tiền mặt, Llama 55, Qwen chỉ 7 $\Rightarrow$ model “ít hào phóng” nhất lại tối ưu kinh tế nhất: đạt mục tiêu mà tổn ít nhất.

So với người: bảng tổng

Khía cạnh	Người (Milinski 2008)	LLM (cả 3)
Nhạy rủi ro	Có (50/10/0%)	Không (100% phẳng)
Hợp tác qua vòng	Giảm dần	Tăng dần
Phản bội cuối game	Có	Không
Mức đóng góp	Vừa đủ	Vượt mục tiêu
Phản ứng persona	—	Có (mạnh nhất)

LLM hợp tác hơn nhưng kém "duy lý chiến lược" so với người.

Cơ chế sâu (đã kiểm chứng đối kháng)

- **"Conditional cooperation" phần lớn là ảo:** sau kiểm soát trong-game, Qwen/Llama hợp tác vô điều kiện, không theo dõi đối tác.
- **Cú "cứu" cuối game** của Gemma-VN là *ramp theo deadline* (đóng mạnh vì game sắp hết), không phải bù trừ theo nhu cầu.
- **Ghi số sai có hệ thống:** Qwen/Llama ghi tổng chỉ $\sim 1/3$ thực tế — nhưng vẫn đạt mục tiêu $\Rightarrow$ hợp tác là *prior*, không phải tính toán.
- **Trục ngôn ngữ:** bù trừ chỉ ở VN; framing nặng hơn ở VN; persona-collapse nặng hơn ở EN.

Điểm thảo luận với thầy

Về prompt

- Khung framing lẫn confound (có câu mục tiêu vs *không*); có cần khối neutral cân bằng?
- Baseline (full history) khác paper — có nên lấy *scratchpad* làm điều kiện chính?

Về phương pháp

- `target_reached` bão hoà 100% $\Rightarrow$ dùng *mức đóng góp* làm biến phụ thuộc chính.
- Lỗi nhỏ: hoán vị ghế phủ chưa đều + "primacy" theo nhãn `Player_1` (ảnh hưởng <3%).

Tác nhân LLM: kẻ hợp tác vô điều kiện, phớt lờ rủi ro, làm ngược đường cong người — và ngôn ngữ là trục điều tiết chính.