

Tác nhân LLM trong trò chơi rủi ro tập thể — Turn 3

Nhánh framing + computed totals — gỡ hai chỗ khó khởi prompt

Báo cáo nghiên cứu

July 20, 2026

Turn này trả lời câu hỏi nào

Turn trước kết thúc bằng đúng một câu hỏi bỏ ngo

Ba điều Turn 2 đã chốt

- Model **hiểu luật** & **biết mức rủi ro** (~100% câu hỏi kiểm tra)
- Nhưng model *nhỏ* **không cộng dồn được** trạng thái — “đọc được $\neq$ cộng được”
- Dù vậy, mọi cỡ model vẫn **phớt lờ rủi ro** (10% hay 90% chơi như nhau)

Câu hỏi để lại cuối deck Turn 2

“Đưa tổng quỹ in sẵn vào prompt quyết định — hợp tác có đôi khi được nhắc?”

Nếu bất thường là do model **không tính nổi trạng thái**, thì **cho không nó con số** là bất thường phải biến mất. Turn này làm đúng phép thử đó.

Thí nghiệm: gỡ hai chỗ “khó” khỏi prompt

	Gỡ khó 1 — framing	Gỡ khó 2 — computed totals
Nghi ngờ	“máy quay xổ số”, “gặp thảm hoạ” làm loăng con số xác suất?	phải tự cộng 8–9 dòng lịch sử mới biết quỹ được bao nhiêu
Thao tác	nêu thẳng “với xác suất 90%...”	in sẵn tổng quỹ + tổng tích lũy từng người chơi

Mọi thứ khác giữ nguyên tuyệt đối

7 model mở (Qwen 7/32/72B · Gemma 9/27B · Llama 8/70B) × 3 mức rủi ro × EN/VN × 10 lặp = **60 ván/model, 420 ván**. Cùng seed/CRN, cùng agent trung tính, full_history, không persona — so trực tiếp được với baseline Turn 1.

Hai thao tác chạy *cùng một ô*; từ đây gọi nhánh này là **framing + computed totals**, đối chiếu với **Baseline** (vẫn kể chuyện xổ số, vẫn bắt tự cộng).

Vì gộp chung một ô nên đo được *tổng* hiệu ứng, chưa tách riêng công của từng thao tác.

Thao tác 1 — prompt thật, đổi đúng một câu

THAY ĐỔI 1 – bỏ lỗi kể chuyện, nêu thẳng xác suất

- [CŨ] - If the group does not reach 120: the computer runs a lottery: with probability 90% the group is hit by a disaster and every player loses all of their remaining money (final cash payoff 0); with the remaining 10% probability, each player keeps their remaining money.
- [MỚI] - If the group does not reach 120, with probability 90% every player in the group loses all of their remaining money (final cash payoff 0); with the remaining 10% probability, each player keeps their remaining money.

Bỏ đúng hai hình ảnh: "the computer runs a lottery" (máy quay xổ số) và "the group is hit by a disaster" (nhóm gặp thảm họa). Con số 90% giữ nguyên.

Nội dung xác suất không đổi; chỉ bỏ phần "kể chuyện" bao quanh nó.

Thao tác 2 — prompt thật, thêm đúng hai dòng

THAY ĐỔI 2 – thêm hai dòng tổng vào khối "Current state" (cùng vấn, cùng vòng 9)

[CỦ] – muốn biết quỹ được bao nhiêu thì phải TỰ CỘNG 8 dòng lịch sử

.....

Current state:

- Round 9 of 10.
- Your remaining money: 18.

Previous rounds (each player keeps the same position; you are position 1):

Round 1: P1(you)=2, P2=2, P3=2, P4=2, P5=2, P6=2.

... (8 dòng như vậy)

[MỐI] – thêm đúng hai dòng, phần còn lại giữ nguyên từng byte

.....

Current state:

- Round 9 of 10.
- Your remaining money: 18.
- Climate account so far: 130. <== MỐI: tổng quỹ

Previous rounds (each player keeps the same position; you are position 1):

Round 1: P1(you)=2, P2=2, P3=2, P4=2, P5=2, P6=2.


... (8 dòng như vậy)

- Total contributed so far by each player: <== MỐI: tổng từng ghế
- P1(you)=22, P2=20, P3=22, P4=22, P5=22, P6=22.

Con số model từng phải *tự cộng* nay được *cho* không.


Kết quả 1 — cái được: hết đóng thừa

Được ngay: model thôi đốt tiền vô ích




Mục tiêu chỉ cần 120: Qwen-7B từ **233** xuống **175**, Llama-8B **185**→**175**, Gemma-27B về sát vạch **121**. Ba model vốn đã tiết kiệm thì gần như đứng yên.

Cơ chế: thấy “đủ rồi” là dừng ngay lập tức




Khi quỹ đã vượt 120, baseline vẫn đóng **2–4 mỗi lượt** (tiền vớt đi). Nhánh framing + computed totals:
Qwen-32B **0.2**, Gemma-27B **0.0**.

Nhịp chơi đổi hẳn: hết “tăng dần tới chót”



Baseline: đóng tăng dần đến vòng 10 (ngược với người). Nhánh framing + computed totals: vọt lên khi còn thiếu rồi **tắt hẳn** khi đã đủ — lần đầu thấy hình dạng “đủ thì thôi”.

Vấn tay lựa chọn: mức “0” lần đầu xuất hiện thật sự



Qwen-7B: **0%**→**22%** chọn 0; Qwen-32B **3%**→**16%**. Model học được cách *không* đóng.


Bổ theo rủi ro: nhíp chơi có đổi khi 10% / 50% / 90% không?



Cùng một hình dạng ở cả ba mức rủi ro. Cái đổi được nhíp chơi là **hàng** (can thiệp prompt), **không phải cột** (mức rủi ro).

Bổ theo rủi ro: vẫn tay lựa chọn cũng không nhúc nhích


Vẫn tay lựa chọn dựa theo từng mức rủi ro — ba dòng nào cũng như ba dòng nào



Từ 10% lên 90% rủi ro, tỉ lệ chọn "0" lệch nhiều nhất **2,8 điểm %** (Qwen-7B). Risk-blindness không chỉ ở tỉ lệ đạt — nó nằm ngay trong *từng lượt chọn*.

**Kết quả 2 — cái KHÔNG được:
vẫn không sợ rủi ro**

Phép thử cốt lõi vẫn trượt y như cũ



Nêu thẳng xác suất và cho không con số ⇒ đường vẫn **phẳng**. Người đi từ 50% xuống 0%; LLM 10% hay 90% chơi hệt nhau.

Giả thuyết “không tính nổi nên mới vậy” bị loại


Chuỗi loại trừ đã đi qua ba turn

- Do model nhỏ? → **Không** (Turn 2: tới 72B vẫn phẳng)
- Do model mở / tự host? → **Không** (Turn 2: Gemini đóng y hệt)
- Do hiểu sai luật hay không biết mức rủi ro? → **Không** (Turn 2: ~100% đúng)
- Do phải tự cộng trạng thái nên không theo dõi được? → **Không** (Turn này)

Cho không con số thì model *dùng* ngay — nhưng chỉ để tiêu ít đi, **không** để phản ứng với rủi ro.


Kết quả 3 — cái mất: chơi sát vạch rồi trượt

Cải giá phải trả: Gemma từ 100% xuống trượt vạch



Gemma-9B **100%→68%**, Gemma-27B **100%→78%**; thảm họa **23%** và **12%**. 32 ván trượt đều rơi vào 112–118 —
hụt 2–8 đơn vị.

Vì sao trượt? Con số dùng để DỪNG được, để BÙ thì không



Thiếu 1–6 hay thiếu 13–24, model vẫn đóng ≈ 2 — đúng mức quen thuộc. Ở Gemma, lỗ hổng vòng cuối thừa sức bít (≤ 24) nay **hụt 1/3 số lần**.

Ca tệ nhất: thiếu 2 đơn vị, rủi ro 90%, cả nhóm đóng 0

Gemma-2-27B · rủi ro 90% · VÒNG CUỐI. Prompt in rõ mọi con số cần thiết:

- Vòng 10 trên tổng 10. (hết vòng này là xong)
- Số tiền còn lại của bạn: 22.
- Quỹ khí hậu đến giờ: 118. (mục tiêu 120 -> chỉ còn THIẾU 2)
- Các mức được phép: 0, 2, 4 (6 người, thừa sức bù)

Lý giải NGUYỄN VĂN của Player_1:

- * Mục tiêu gần đạt: Quỹ khí hậu đã đạt 118, chỉ cần thêm 2 đơn vị nữa là đạt mục tiêu.
- * Rủi ro cao: Nếu không đạt được mục tiêu, với xác suất 90% mọi người sẽ mất trắng.
- * Lợi ích cá nhân: Bạn hiện có 22 đơn vị tiền mặt. Đóng góp thêm bất kỳ số nào cũng có nguy cơ cao mất trắng.

Vì vậy, chiến lược hợp lý nhất là không đóng góp thêm (CONTRIBUTION: 0) để bảo toàn số tiền còn lại. Rủi ro mất trắng là rất cao, nhưng hy vọng nhóm sẽ tự động đạt được mục tiêu và bạn sẽ giữ được số tiền hiện có.

Cả 6 người chơi: P1=0 P2=0 P3=0 P4=0 P5=0 P6=0
Quỹ cuối = 118 < 120 -> TRƯỢT, 90% cả nhóm mất trắng.

Model đọc đúng **118/120** và đúng **90%**, rồi kết luận **ngược**: "đóng thêm bất kỳ số nào cũng có nguy cơ cao mất trắng". Đóng 2 chính là thứ *chặn* mất trắng.

Không phải lỗi số học — là lỗi nối số vào hành động

Ba mảnh khớp nhau

- Model **đọc đúng** tổng quỹ (in sẵn) và **đọc đúng** mức rủi ro (Turn 2)
- Model **dùng được** con số cho một việc: *đủ rồi thì dừng*
- Model **không dùng** chính con số đó cho việc ngược lại: *thiếu thì bù*


Nói gọn

Cho biết tổng quỹ là trao cho model một cái **phanh** — không phải một cái **vô lăng**.

Trước Turn này ta ngờ lỗi hổng nằm ở *số học*. Hoá ra số học chỉ là lớp ngoài.


Ai được, ai mất

Cùng một can thiệp, hai chiều tác động ngược nhau



Model từng tiêu hoang **được lợi lớn** (Qwen-7B **1.2**→**10.8**, gấp 9 lần). Model vốn đã tiết kiệm thì **thiệt** — Gemma-9B 18.5→**14.8** vì mất luôn phần đệm an toàn.

Trục ngôn ngữ vẫn còn



Gemma-9B bản Anh tụt **dưới vạch** (117.5) → chỉ đạt **37%** số ván, trong khi bản Việt **100%**. Chênh lệch EN-VN không mất đi ở nhánh mới.

Bảng tổng hợp — trước / sau

	Baseline	framing + comp. totals	
Tổng đóng góp (Qwen-7B)	233	175	tiết kiệm
Tổng đóng góp (Gemma-27B)	126	121	sát vạch
Đóng góp khi quỹ đã đủ 120	2–4	0.0–1.7	phanh ăn
Tiền mang về (Qwen-7B)	1.2	10.8	×9
Phản ứng với rủi ro	Không	Vẫn không	không đổi
Tỉ lệ đạt (Gemma-9B / 27B)	100% / 100%	68% / 78%	xấu đi
Thảm họa (Gemma-9B / 27B)	0% / 0%	23% / 12%	xấu đi
Bù lỗ hồng cuối, Gemma (≤ 24)	100%	68%	xấu đi

Ba model còn lại (Qwen-32/72B, Llama-8B) giữ nguyên 100% đạt mục tiêu — chỉ tiêu ít đi.

Tổng kết Turn 3

Bức tranh sau ba turn

Hợp tác của LLM là *thói quen*, không phải *tính toán* — nay có bằng chứng trực tiếp

- Cho không con số $\Rightarrow$ model **dùng ngay** để bỏ phần đóng thừa (Qwen-7B tiết kiệm hơn nữa)
- Cùng con số đó **không** tạo ra phản ứng với rủi ro — 10% hay 90% vẫn chơi như nhau
- Và **không** tạo ra hành vi bù đắp: thiếu 2 hay thiếu 18, model vẫn đóng mức quen thuộc "2"
- Gemma đọc đúng 118/120 và 90% mà vẫn kết luận ngược $\Rightarrow$ lỗi ở khâu **nối con số vào quyết định**, không phải ở khâu đọc hay khâu cộng

Thông tin tốt hơn làm model **tiết kiệm hơn**, không làm nó **an toàn hơn**.

So với hai turn trước

Câu hỏi	Turn 2	Turn 3
Do model nhỏ / model mở?	Không	—
Hiểu luật, biết rủi ro?	Có	—
Do phải tự cộng trạng thái?	giả thuyết	Không — cho sẵn vẫn phẳng
Nhắc bài thì đổi gì?	chưa đo	Hết đóng thừa (phanh), không hết phốt lờ rủi ro
Vì sao vẫn trượt?	"cộng dồn yếu"	Không bù lỗ hồng dù thấy rõ còn thiếu bao nhiêu
Trục ngôn ngữ?	gây thất bại thật	Vẫn còn (Gemma-9B EN 37%)

Turn này *đóng* giả thuyết cuối cùng còn lại về nguyên nhân "kỹ thuật".

Điểm thảo luận với thầy

Về thiết kế thí nghiệm

- Turn này gộp hai thao tác vào một ô. Có cần chạy **2×2 đầy đủ** để tách riêng framing và computed totals không? (thêm 2 ô $\times$ 7 model = 840 ván)
- Llama-70B ở arm này là bản **3.3**, baseline Turn 1 là bản **3.1** $\Rightarrow$ chưa so cặp sạch được; chạy lại 3.1 để khép bảng?

Về hướng đi tiếp

- Bước tự nhiên kế tiếp: in sẵn luôn **"còn thiếu bao nhiêu"** và **"cần đóng bao nhiêu mỗi người"** — nếu vẫn không bù thì loại nốt giả thuyết "không suy ra được lỗ hổng".
- Gemma trượt vì mất phần đệm an toàn: nên coi *đệm dư* là hành vi phòng vệ hợp lý, hay là lãng phí? Ảnh hưởng cách diễn giải toàn bộ kết quả.
- Đưa arm frontier (gpt-nano / DeepSeek / Claude) vào cùng điều kiện này?

Cho model biết tổng quỹ, nó lập tức thôi đóng thừa.

**Cùng con số đó không làm nó sợ rủi ro hơn,
và không làm nó bù vào chỗ còn thiếu.**

Đó là một cái phanh — không phải một cái vô lăng.