

Tác nhân LLM trong trò chơi rủi ro tập thể — Tuần 2

Hai mở rộng: *phóng to model* (scaling) & *kiểm tra đọc-hiểu* (comprehension)

Báo cáo nghiên cứu

June 28, 2026

Tuần này làm gì

Nhắc lại kết luận tuần trước (3 model nhỏ, baseline)

LLM chơi collective-risk game KHÁC con người

- **Phốt lờ rủi ro**: đạt mục tiêu $\sim 100\%$ ở cả 3 mức rủi ro (người: 50/10/0%).
- **Hợp tác TĂNG dần** qua vòng, không phản bội cuối game (ngược người).
- **Vượt mục tiêu**: Qwen-7B ~ 233 , Llama-8B ~ 185 , Gemma-9B ~ 129 .

Hai câu hỏi còn treo $\Rightarrow$ hai thí nghiệm tuần này

1. Các bất thường này có phải vì model *nhỏ*? $\rightarrow$ Large model (scaling).
2. Phốt-lờ-rủi-ro là *không hiểu luật* hay *cố tình*? $\rightarrow$ Comprehension.

Thiết lập hai thí nghiệm mới

	5 · Large model (scaling)	6 · Comprehension
Mục tiêu	bất thường có do cỡ model?	model có HIỂU luật không?
Model	Qwen 7B→32B, Gemma 9B→27B	3 model nhỏ (như baseline)
Điều kiện	baseline trung tính (y hết tuần 1)	probe IN-SITU trong ván baseline
Đo gì	reach, đóng góp, vân tay, vòng	accuracy 20 câu hỏi/3 trực
Quy mô	60 ván/model (3 risk×2 lang×10)	~54.5k probe/model

Comprehension — phỏng theo “Nicer Than Humans” (Fontana et al. 2024)

Mỗi vòng bắt THÊM câu hỏi Rules / Time / State, gửi RIÊNG (không đưng quyết định), chấm so ground-truth của engine. Hai nhánh A/B: showCumulative pool ẩn (như baseline) vs pool hiện (tái lập Figure A7).

5 · Large model (scaling)

Scaling — câu hỏi & cách đọc


Thao tác

Giữ NGUYÊN prompt baseline trung tính của tuần 1, chỉ **thay model**: Qwen2.5-7B→32B, Gemma-2-9B→27B. Llama-3.1-8B giữ làm mốc tham chiếu. Cùng 3 mức rủi ro $\times \{EN, VN\} \times 10$ lần lặp.

Hai giả thuyết cạnh tranh


- *H1 — “do model nhỏ”*: model lớn sẽ nhạy rủi ro hơn, giống người hơn.
- *H2 — “đặc tính bền”*: bất thường vẫn còn; chỉ phần *kinh tế* thay đổi.

Scaling — Qwen thôi hào phóng, hội tụ về “vừa đủ 120”




Phóng to Qwen 7B→32B kéo đóng góp 233→128 (−105); Gemma 9B→27B gần như đứng yên (129→126). Model lớn hội tụ về cùng một chiến lược “ép sát mục tiêu” — Gemma vốn đã ở đó.

Scaling — KHÔNG phục hồi nhạy-rủi-ro (H2 thắng)




Cả Qwen-32B lẫn Gemma-27B vẫn đạt mục tiêu ~100% ở mọi mức rủi ro (đường người dốc 50→10→0%). Phớt-lờ-rủi-ro **bền theo cỡ model** — không phải lỗi của model nhỏ.

Scaling — “vân tay” lựa chọn LẬT về mức 2




Qwen-7B kịch trần (94% chọn 4) nhưng Qwen-32B đổi sang 88% chọn 2 — đúng mức “fair-share” mà Gemma đã khoá. Model càng lớn càng kinh tế: bỏ thói quá-đóng-góp, chỉ đóng vừa đủ phần công bằng.

Scaling — vẫn tăng dần, “ép vạch” sát deadline



Model lớn giữ phẳng ở 2.0 gần hết game rồi *ramp* ở vòng 9–10 (Gemma-27B: 2.0→2.87). Vẫn là quỹ đạo **tăng dần** ngược người — chỉ “ép sát ngưỡng” muộn và gọn hơn, tiết kiệm hơn model nhỏ.

Scaling — trực ngôn ngữ co lại (Llama vẫn lệch nhất)



Khoảng cách EN–VN của Qwen co từ -10 (7B) còn -3 (32B); Gemma-27B đảo dấu nhẹ (-13). Llama-8B vẫn lệch mạnh nhất (-44). Phóng to làm hành vi *ổn định hơn* giữa hai ngôn ngữ, nhưng không xóa trục này.

Scaling — chốt phần 5

Khía cạnh	Nhỏ (7–9B)	Lớn (27–32B)
Nhạy rủi ro	Không (100% phẳng)	Không (100% phẳng)
Hợp tác qua vòng	Tăng dần	Tăng dần (ramp muộn)
Mức đóng góp Qwen	233 (kịch trần 4)	128 (về mức 2)
Mức đóng góp Gemma	129	126 (gần như không đổi)
Tiền mặt giữ (Qwen)	7/240	112/240

Phóng to model = *kinh tế hơn*, KHÔNG phải *nhạy rủi ro hơn*. Bất thường cốt lõi (phớt-lờ-rủi-ro, tăng dần) là đặc tính bền, không phải hạn chế dung lượng.

6 · Comprehension (đọc-hiểu)

Comprehension — thiết kế probe

20 câu hỏi · 3 trục (chấm so ground-truth engine)

RULES (luật tính: mức đóng, vốn, mục tiêu, số vòng, % rủi ro, payoff) · **TIME** (tra lịch sử: đang vòng mấy, ai đóng bao nhiêu ở vòng i) · **STATE** (thống kê tích lũy: quỹ hiện có, còn thiếu bao nhiêu — phần lớn phải *tự cộng dồn*).


```
[RULES . risk] Q: If the group does NOT reach the target, what is the
percent chance (0-100) that everyone loses all of their remaining money?
model -> ANSWER: 90          ground-truth 90    [DUNG] -> BIET ro muc rui ro
```

```
[STATE . pool AN, vong 5] Q: Across all rounds played so far, what is the
total amount currently in the climate account (all players combined)?
model -> ANSWER: 24          ground-truth 96    [SAI] -> chỉ lay 1 vong, khong cong don
```

```
[STATE . pool HIEN, vong 5] cung cau hoi, prompt C0 in san tong quy:
model -> ANSWER: 96          ground-truth 96    [DUNG] -> doc duoc la dung ngay
```


Cùng một câu STATE: pool ẮN model đáp 24 (chỉ một vòng) thay vì 96; pool HIỆN đáp đúng ngay.

Comprehension — hiểu LUẬT & đọc LỊCH SỬ tốt, sụp ở CỘNG DỒN




Rules 94–100%, Time 82–99% — model *hiểu luật* và *tra được lịch sử*. Nhưng State (cộng đồn) chỉ 32–72%: Gemma 72% > Qwen 37% > Llama 32%. Lỗi hổng nằm ở **số học tích lũy**, không phải ở luật chơi.

Comprehension — ĐỌC được $\neq$ CỘNG được (kết quả sắc nhất)



Số IN SẴN trong prompt (own_remaining): 66–100%. Cùng loại “tổng quỹ” nhưng PHẢI cộng dồn: pool ẨN chỉ 10–21%; khi prompt IN sẵn tổng thì vọt lên 92–100%. Model đọc được nhưng không cộng được — đúng Figure A7 của “Nicer Than Humans”.


Comprehension — CỒNG: họ BIẾT rủi ro, chỉ là phớt lờ



Câu “rủi ro bao nhiêu %” được trả đúng ~100% (Qwen 98, Gemma 100, Llama 91). Vậy phớt-lờ-rủi-ro **KHÔNG** phải do hiểu sai luật — model biết rõ 90/50/10% nhưng vẫn chọn như nhau.

Đây là *cồng* hợp thức hoá claim hành vi của tuần trước.


Comprehension — tiếng Việt đánh đúng vào cộng đồn



Rules/Time gần như không đổi giữa EN/VN (−2/−5pp); nhưng State rất −19pp ở tiếng Việt (Gemma nặng nhất: −32pp). Trục ngôn ngữ tấn công đúng khâu yếu nhất — *số học trạng thái* — chứ không phải khả năng đọc luật.

Comprehension — bảng chi tiết 20 câu (phụ lục)

Comprehension theo từng câu hỏi (Rules | Time | State) — CRG



Trần ở Rules; Time tốt trừ `time_round_total_i` (phải cộng 6 ghế trong 1 vòng). State lủng đều: `state_X_total`, `state_own_total`, `state_rounds_left` đều thấp. Riêng `state_pool` nhảy rõ giữa hai panel (ẩn→hiện).

Tổng hợp tuần 2

Hai mảnh ghép vào bức tranh chung

Cơ chế hợp tác của LLM = *prior*, không phải *tính toán*

- **Comprehension:** model HIỂU luật & BIẾT rủi ro (Rules ~100%, risk-gate ~100%) nhưng KHÔNG cộng được trạng thái (State 10–21% khi phải tự tính).
- **Hệ quả:** hợp tác vẫn đạt mục tiêu dù ghi sổ sai $\Rightarrow$ là thiên kiến hợp tác có sẵn, không phải suy luận chiến lược theo trạng thái.
- **Scaling:** phóng to chỉ cắt phần *lãng phí* (Qwen 233 $\rightarrow$ 128) — làm model *kinh tế hơn*, nhưng giữ nguyên phốt-lờ-rủi-ro & tăng-dần.

Phốt-lờ-rủi-ro KHÔNG phải lỗi hiểu (comprehension bác bỏ) cũng KHÔNG phải lỗi dung lượng (scaling bác bỏ) $\Rightarrow$ là một **thiên kiến hành vi** của lớp model này.

So với tuần trước: cập nhật bảng tổng

Câu hỏi	Trả lời tuần trước	Bảng chứng tuần này
Do model nhỏ?	(giả thuyết)	Không — 27/32B vẫn phẳng 100%
Có hiểu luật không?	(chưa đo)	Có — Rules 94–100%
Có biết mức rủi ro?	(chưa đo)	Có — risk-gate ~100%
Vì sao ghi sổ sai?	"hợp tác là prior"	Không cộng dồn được (State 10–21%)
Trục ngôn ngữ ở đâu?	đóng góp (Llama)	+ số học trạng thái (State – 19pp VN)

Hai thí nghiệm *khẳng định* và *giải thích* các bất thường của tuần 1, thay vì lật chúng.

Điểm thảo luận với thầy

Về scaling

- Chưa có Llama lớn (70B) — có cần để hoàn tất cặp họ thứ ba?
- Qwen-32B tụt nhẹ reach (97%) vì chơi sát vạch 120 — có nên báo cáo đóng góp làm biến chính (như đã chốt tuần trước)?

Về comprehension

- “Không cộng dồn được” là giới hạn số học hay do prompt quá dài? → đề xuất ablation *độ dài lịch sử* (probe theo vòng).
- Có nên đưa *một câu state-pool* vào prompt quyết định để xem hợp tác có đổi khi model “được nhắc” tổng quỹ?

Phóng to model làm nó kinh tế hơn, không nhạy rủi ro hơn.

LLM hiểu luật và biết rủi ro — nhưng không cộng được trạng thái:

hợp tác là thiên kiến có sẵn, không phải tính toán.