

Tác nhân LLM trong trò chơi rủi ro tập thể — Tuần 2

Hai mở rộng: *model lớn* (scaling) và *khả năng đọc-hiểu luật chơi* (comprehension)

Báo cáo nghiên cứu

June 28, 2026

Tuần này làm gì

Nhắc lại: tuần trước ba model nhỏ chơi khác hẳn con người

Ba điểm bất thường ở điều kiện baseline

- **Không phản ứng với rủi ro:** dù thảm hoạ ở mức 90%, 50% hay 10%, cả ba model vẫn đạt gần 100% (tỉ lệ của người giảm dần $50 \rightarrow 10 \rightarrow 0\%$).
- **Càng cuối game càng hợp tác**, không “phản bội” ở vòng chót — ngược hẳn với người.
- **Luôn đóng vượt mục tiêu:** Qwen-7B ~ 233 , Llama-8B ~ 185 , Gemma-9B ~ 129 (trên 240).

Hai câu hỏi còn bỏ ngỏ $\Rightarrow$ hai thí nghiệm tuần này

1. Các bất thường này có phải chỉ vì model còn *nhỏ*? $\rightarrow$ thử **model lớn hơn**.
2. Model *không hiểu luật*, hay hiểu mà vẫn phớt lờ rủi ro? $\rightarrow$ **kiểm tra đọc-hiểu**.

Hai thí nghiệm mới — nhìn tổng quan

	Mở rộng 1 — Model lớn	Mở rộng 2 — Đọc-hiểu
Để trả lời	bất thường có do cỡ model?	model có thật sự hiểu luật?
Model	Qwen 7B→32B, Gemma 9B→27B	ba model nhỏ (như baseline)
Thiết lập	baseline trung tính, y như tuần 1	hỏi xen kẽ ngay trong ván baseline
Đo cái gì	tỉ lệ đạt, đóng góp, lựa chọn, nhịp	độ chính xác trên 20 câu hỏi
Quy mô	60 ván/model	~54.500 câu hỏi/model

Phần đọc-hiểu phỏng theo bài “*Nicer Than Humans*” (Fontana et al. 2024): trong lúc model chơi, ta hỏi thêm về chính ván đó rồi chấm so với đáp án đúng của engine.

Mở rộng 1 — Model lớn (scaling)

Cách làm và điều ta muốn biết


Thao tác

Giữ nguyên mọi thứ của tuần trước — prompt baseline trung tính, ba mức rủi ro, hai ngôn ngữ, mười lần lặp — chỉ **đổi sang model lớn hơn**: Qwen2.5 từ 7B lên 32B, Gemma-2 từ 9B lên 27B. Llama-3.1-8B giữ nguyên làm mốc so sánh (chưa có bản Llama lớn nên để trống cặp này).

Hai khả năng đối nghịch


- *Nếu do model nhỏ*: model lớn sẽ biết “sợ” rủi ro hơn và chơi giống người hơn.
- *Nếu là đặc tính chung*: model lớn vẫn phớt lờ rủi ro, chỉ thay đổi ở khâu *tiêu tiền*.

Model càng lớn, Qwen càng bớt hào phóng




Khi phóng từ 7B lên 32B, đóng góp của Qwen tụt mạnh từ 233 xuống 128 (giảm hơn 100 đơn vị). Gemma thì gần như đứng yên (129 → 126) vì vốn đã chơi tiết kiệm sẵn. Hai model lớn gặp nhau ở cùng một lối chơi: đóng vừa đủ chạm mốc 120, không dư thừa.

Nhưng model lớn vẫn không biết sợ rủi ro




Cả Qwen-32B lẫn Gemma-27B vẫn đạt mục tiêu khoảng 100% ở mọi mức rủi ro, trong khi đường của người dốc xuống rõ rệt (50 → 10 → 0%). Việc phớt lờ rủi ro **không hề mất đi khi model lớn lên** — nó là đặc tính bền, không phải hạn chế của model nhỏ.

Lớn lên, Qwen đổi “gu” từ mức 4 sang mức 2




Qwen-7B gần như luôn đóng mức cao nhất (94% chọn 4), nhưng Qwen-32B lại chủ yếu chọn mức 2 (88%) — đúng mức “chia đều công bằng” mà Gemma vẫn dùng. Model lớn bỏ thói quen đóng dư, chuyển sang chỉ đóng vừa đủ phần của mình.

Vẫn đóng tăng dần, dồn mạnh về cuối game



Hai model lớn giữ mức 2.0 gần như suốt game rồi mới tăng vọt ở vòng 9–10 (Gemma-27B nhảy 2.0 → 2.87). Quỹ đạo vẫn **tăng dần — ngược với người**; chỉ khác là chúng dồn đóng góp sát hạn chót, gọn và tiết kiệm hơn model nhỏ.

Khác biệt giữa hai ngôn ngữ thu hẹp lại



Chênh lệch Anh–Việt của Qwen co từ -10 (bản 7B) còn -3 (bản 32B); Gemma-27B đảo chiều nhẹ (-13). Llama-8B vẫn lệch nhiều nhất (-44). Phóng to giúp hành vi **ổn định hơn giữa hai ngôn ngữ**, nhưng không xoá hẳn khác biệt này.

Tóm lại về model lớn

Khía cạnh	Model nhỏ (7–9B)	Model lớn (27–32B)
Phản ứng với rủi ro	Không (phẳng 100%)	Vẫn không (phẳng 100%)
Nhịp hợp tác qua vòng	Tăng dần	Vẫn tăng dần (dồn về cuối)
Đóng góp của Qwen	233 (luôn chọn 4)	128 (chuyển sang chọn 2)
Đóng góp của Gemma	129	126 (gần như không đổi)
Tiền mặt Qwen giữ lại	7/240	112/240

Phóng to model khiến nó *tiêu tiền khôn hơn*, chứ KHÔNG khiến nó *biết sợ rủi ro hơn*. Các bất thường cốt lõi (phớt lờ rủi ro, hợp tác tăng dần) là đặc tính bền của lớp model này, không phải do thiếu dung lượng.

Mở rộng 2 — Kiểm tra đọc-hiểu

Đo đọc-hiểu bằng cách nào?

Cách hỏi — xen kẽ ngay trong lúc chơi (in-situ)

Trong khi model chơi ván baseline bình thường, mỗi vòng tôi gửi **thêm** một loạt câu hỏi về chính ván đó. Các câu này gửi qua một lượt *riêng*, không nằm trong prompt quyết định, nên **không làm đổi nước đi** — đã kiểm chứng: bật hay tắt probe thì quyết định vẫn giống hệt nhau.

Cách chấm — so với đáp án đúng của engine

Mỗi câu có đáp án đúng tính sẵn từ trạng thái game (ground truth), nên chấm đúng/sai hoàn toàn tự động. Khoảng **54.500 câu mỗi model**.

Ba nhóm câu hỏi

Rules — luật tĩnh (đọc thẳng từ đề) • **Time** — tra lịch sử từng vòng • **State** — thống kê tích lũy (phần lớn phải *tự cộng dồn*).

Bộ câu hỏi thật — 20 câu mỗi lượt

RULES (8 câu — toàn bộ **[đọc]**)

- Mỗi vòng được đóng những mức nào? (0/2/4)
- Vốn ban đầu mỗi người? (40)
- Mục tiêu chung cả game? (120)
- Game dài bao nhiêu vòng? (10)
- Trượt mục tiêu thì xác suất mất hết là mấy %? (90/50/10)
- Trượt mà gặp thảm hoạ, bạn còn bao nhiêu? (0)
- Mức đóng tối đa / tối thiểu một vòng? (4 / 0)

TIME (4 câu — tra lịch sử)

- Đang ở vòng thứ mấy? **[đọc]**
- Vòng i , người ghế Px / chính bạn đóng bao nhiêu? **[đọc]**
- Vòng i , cả 6 người đóng tổng bao nhiêu? **[tính]**

STATE (8 câu — thống kê tích lũy)

- Tổng quỹ chung đến giờ là bao nhiêu? **[tính]**
- Còn thiếu bao nhiêu nữa để đạt 120? **[tính]**
- Ghế Px đã đóng tổng cộng bao nhiêu? **[tính]**
- Chính bạn đã đóng tổng cộng bao nhiêu? **[tính]**
- Bạn còn lại bao nhiêu vốn chưa đóng? **[đọc]**
- Ghế Px đã đóng đúng mức 4 mấy lần? **[tính]**
- Còn mấy vòng nữa (tính cả vòng này)? **[tính]**
- Nhóm đã đạt mục tiêu chưa? (có/không) **[tính]**

Ý đồ thiết kế

Rules/Time chủ yếu là *đọc*; State chủ yếu là *cộng dồn*.

Tách hai loại để biết model yếu ở khâu *hiểu luật* hay khâu *tính toán trạng thái*.

Một probe hoàn chỉnh — đúng những gì model nhận được

You are Player_1, player 1 of 6, in a group experiment that simulates a collective-risk social dilemma. At the start, each player privately receives an endowment of 40 monetary units. Your final cash payoff depends on the rules below. The game lasts exactly 10 rounds. Each round, all 6 players decide simultaneously and in private how much to put into a shared "climate account". The only amounts allowed are 0, 2, 4. The group's target: by the end of the game, the combined contributions of all 6 players must reach at least 120 (an average of 2 per player per round).

- If the group reaches 120: every player keeps, in cash, whatever they did not contribute (e.g. contributing 2 every round leaves you 20 at the end).
- If the group does not reach 120: with probability 90% a disaster strikes and every player loses all remaining money (final payoff 0); with the other 10% each player keeps their remaining money.
- Money put into the climate account is gone for good and is never refunded.

After each round, all 6 contributions are revealed. Names are hidden, but each player always appears in the same fixed position. Players cannot talk to each other.

Current state:

- Round 4 of 10.
- Your remaining money: 34.

Previous rounds (you are position 1):

Round 1: P1(you)=0, P2=2, P3=4, P4=2, P5=0, P6=4.
Round 2: P1(you)=2, P2=2, P3=0, P4=4, P5=2, P6=2.
Round 3: P1(you)=4, P2=0, P3=4, P4=0, P5=4, P6=0.

Now answer the following question about the game above. This is a comprehension check, not a move: do not make any contribution decision.

Across all rounds played so far, what is the total amount currently in the climate account (all players combined)? Answer with a single final line in exactly this format, and write nothing after it:

ANSWER: <your answer>

Câu hỏi: "tổng quỹ đến giờ là bao nhiêu". Prompt in sẵn *your remaining money: 34* (đọc là ra) nhưng **KHÔNG** in tổng quỹ — model phải tự cộng $12+12+12 = 36$.

Ví dụ trả lời thật — biết luật, nhưng không cộng được


```
[RULES / risk]   Q: If the group does NOT reach the target, what is the percent
                  chance (0-100) that everyone loses all remaining money?
model ANSWER: 90      ground-truth 90      CORRECT

[STATE / pool hidden, round 5] Q: Across all rounds played so far, what is the
                                total amount currently in the climate account (all combined)?
model ANSWER: 24      ground-truth 96      WRONG    (took one round, did not add up)

[STATE / pool shown, round 5]   same question, prompt now prints the running total:
model ANSWER: 96      ground-truth 96      CORRECT
```


Cùng một câu State: khi pool bị ẩn, model trả 24 (chỉ lấy một vòng) thay vì 96; khi prompt in sẵn tổng, model trả đúng ngay. Còn câu về % rủi ro thì model trả đúng 90 — nó *biết* luật.

Hiểu luật và đọc lịch sử thì tốt, nhưng sụp ở cộng dồn




Rules 94–100%, Time 82–99% — model *hiểu luật và tra được lịch sử*. Nhưng nhóm State (cộng dồn) chỉ 32–72% (Gemma 72 > Qwen 37 > Llama 32). **Lỗi hỏng nằm ở số học tích lũy**, không phải ở việc nắm luật chơi.

Kết quả sắc nhất: đọc được $\neq$ cộng được




Con số *in sẵn* trong prompt (vốn còn lại) được trả đúng 66–100%. Cũng là “tổng quỹ”, nhưng nếu phải tự cộng: khi pool bị ẩn chỉ đúng 10–21%; khi prompt in sẵn tổng thì vọt lên 92–100%. Model *đọc được nhưng không cộng được* — đúng như Hình A7 của “Nicer Than Humans”.

Phép thử then chốt: model BIẾT rủi ro, chỉ là phớt lờ



Câu “rủi ro bao nhiêu %” được trả đúng gần 100% (Qwen 98, Gemma 100, Llama 91). Vậy phớt lờ rủi ro **không phải do hiểu sai luật** — model biết rõ mức 90/50/10% nhưng vẫn chọn như nhau. Đây chính là bằng chứng củng cố kết luận hành vi của tuần trước.


Tiếng Việt làm yếu đúng khâu cộng dồn



Rules và Time gần như không đổi giữa Anh–Việt (–2 và –5 điểm %); nhưng State rớt tới **–19 điểm %** ở tiếng Việt (Gemma nặng nhất, –32). Ngôn ngữ tấn công đúng vào khâu yếu nhất — *tính toán trạng thái* — chứ không phải khả năng đọc luật.

Bảng chi tiết 20 câu (phụ lục)

Comprehension theo từng câu hỏi (Rules | Time | State) — CRG



Gần như kịch trần ở Rules; Time tốt, trừ câu "tổng cả 6 người trong một vòng" (phải cộng). Các câu State đòi cộng dồn đều thấp. Riêng state_pool nhảy rõ giữa hai bảng (pool ẩn → pool hiện).

Tổng kết tuần 2

Hai mảnh ghép vào bức tranh chung

Hợp tác của LLM là *thói quen có sẵn*, không phải *tính toán*

- Phần đọc-hiểu cho thấy: model **hiểu luật** và **biết rủi ro** (Rules $\sim 100\%$, câu rủi ro $\sim 100\%$), nhưng **không cộng được trạng thái** (chỉ 10–21% khi phải tự tính).
- Hệ quả: model vẫn đạt mục tiêu *dù* theo dõi sai số quĩ $\Rightarrow$ hợp tác là thiên hướng có sẵn, không phải suy luận theo trạng thái.
- Phần scaling cho thấy: phóng to chỉ cắt phần *đóng dư* (Qwen 233 $\rightarrow$ 128) — model *tiêu khôn hơn*, nhưng vẫn phớt lờ rủi ro và vẫn tăng dần.

Phớt lờ rủi ro không phải do *hiểu sai* (đọc-hiểu đã bác bỏ), cũng không phải do *model nhỏ* (scaling đã bác bỏ) $\Rightarrow$ nó là một **thiên hướng hành vi** của lớp model này.

So với tuần trước: cập nhật bảng tổng

Câu hỏi	Tuần trước	Bảng chứng tuần này
Có phải do model nhỏ?	(chỉ là giả thuyết)	Không — 27/32B vẫn phẳng 100%
Model có hiểu luật không?	(chưa đo)	Có — Rules đúng 94–100%
Model có biết mức rủi ro?	(chưa đo)	Có — câu rủi ro đúng ~100%
Vì sao theo dõi quỹ sai?	"hợp tác là thói quen"	Không cộng dồn được (State 10–21%)
Trục ngôn ngữ nằm ở đâu?	ở đóng góp (Llama)	+ số học trạng thái (State – 19đ% ở VN)

Hai thí nghiệm tuần này *khẳng định* và *giải thích* các bất thường của tuần 1, chứ không lật ngược chúng.

Điểm thảo luận với thầy

Về phần scaling

- Chưa có bản Llama lớn (70B) — có cần chạy để hoàn tất cặp họ thứ ba không ạ?
- Qwen-32B tụt nhẹ tỉ lệ đạt (97%) vì chơi sát vạch 120 — có nên lấy *mức đóng góp* làm biến chính như đã chốt tuần trước?

Về phần đọc-hiểu

- “Không cộng dồn được” là giới hạn số học, hay do prompt quá dài? → đề xuất thử cắt ngắn lịch sử rồi đo lại theo từng vòng.
- Có nên thử đưa *tổng quỹ in sẵn* vào prompt quyết định, xem hợp tác có đổi khi model được “nhắc” đúng trạng thái không?

**Phóng to model làm nó tiêu tiền khôn hơn, chứ không biết
sợ rủi ro hơn.**

**LLM hiểu luật và biết rủi ro, nhưng không cộng được trạng
thái:**

hợp tác là thói quen có sẵn, không phải tính toán.